



Universidad Nacional de La Plata

REGRESIÓN LINEAL

Modelo de regresión

Matemática IV

Facultad de
Informática

DISCLAIMER



Esta presentación es
complementaria al apunte teórico
provisto y a las clases brindadas
sobre el tema



La misma no debe reemplazar al
mismo a la hora de estudiar y
asimilar el tema




Cualquier duda que surja a partir
de ambos materiales debe ser
consultada en clase

MOTIVACIÓN

La regresión lineal es una herramienta estadística de análisis de datos y sistemas. Consiste en armar un estadístico de una variable dependiente a partir de una variable independiente y muestras que relacionen ambos elementos.

IMPORTANTE: El comportamiento no es determinístico.




MOTIVACIÓN

La idea: los datos tienen una relación lineal, o proporcional.

Esto es equivalente a decir que el cambio en la variable dependiente es constante.

Esta relación tiene, además, un componente de error, que se asume aleatorio.



EL MODELO

Definición 1.2. MODELO DE REGRESIÓN LINEAL SIMPLE

*Existen parámetros β_0 , β_1 y σ^2 de tal suerte que con cualquier valor fijo de la variable independiente x , la variable dependiente está relacionada con x por medio de la **ecuación de modelo***

$$Y = \beta_0 + \beta_1 x + e$$

La cantidad e en la ecuación de modelo es una variable aleatoria, que se supone está normalmente distribuida con $E(e) = 0$ y $V(e) = \sigma^2$

ESTIMAR LA RECTA

¿Cuál es la mejor recta?



Una vez planteada la recta de regresión lineal, se requiere hallar una función que, en base a las muestras, calcule los coeficientes que estimen la recta más precisa. Para eso, se debe elegir una métrica que indique qué tan exacta o ajustada es la muestra.

Mínimos Cuadrados



El método utilizado para estimar la recta es el método de mínimos cuadrados.

Este método calcula los coeficientes de la recta de tal modo que **la suma de los cuadrados de los errores** sea mínima.

EL MÉTODO

Definición 1.3. MÉTODO DE MÍNIMOS CUADRADOS

La desviación vertical del punto (x_i, y_i) con respecto a la línea $y = \beta_0 + \beta_1 x$ es

$$\text{la altura del punto} - \text{altura de la línea} = y_i - (\beta_0 + \beta_1 x)$$

La suma de las desviaciones verticales al cuadrado de los puntos $(x_1, y_1), \dots, (x_n, y_n)$ a la línea es entonces

$$f(b_0, b_1) = \sum_{i=1}^n [y_i - (b_0 + b_1 x_i)]^2$$

*Las estimaciones puntuales de β_0 y β_1 , denotadas por $\hat{\beta}_0$ y $\hat{\beta}_1$ llamadas **estimaciones de mínimos cuadrados**, son aquellos valores que reducen al mínimo a $f(b_0, b_1)$. Es decir, $\hat{\beta}_0$ y $\hat{\beta}_1$ son tales que*

$$f(\hat{\beta}_0, \hat{\beta}_1) \leq f(b_0, b_1) \quad \forall b_0, b_1$$

La línea de regresión estimada o línea de mínimos cuadrados es entonces la línea cuya ecuación es

$$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x$$

CÁLCULO DE LA RECTA

$$\frac{\partial f(b_0, b_1)}{\partial b_0} = \sum_{i=1}^n -2(y_i - b_0 - b_1 x_i) = 0$$

$$\frac{\partial f(b_0, b_1)}{\partial b_1} = \sum_{i=1}^n -2x_i(y_i - b_0 - b_1 x_i) = 0$$

$$nb_0 + b_1 \left(\sum_{i=1}^n x_i \right) = \sum_{i=1}^n y_i$$

$$b_0 \left(\sum_{i=1}^n x_i \right) + b_1 \left(\sum_{i=1}^n x_i^2 \right) = \sum_{i=1}^n x_i y_i$$

Planteo de mínimo

Para hallar los mínimos de la función de mínimos cuadrados, deben plantearse la/las derivada/s y hallar el punto crítico/estacionario.

- Si se conoce alguno de los coeficientes, es una ecuación de una variable (Ejs. 1 y 2 del TP)
- De desconocer ambos coeficientes, se plantean ambas derivadas parciales y se busca el punto estacionario.

Resolución

Resolviendo las derivadas parciales, resultan las cuentas de la izquierda.

LAS PELIGROSAS

La estimación de mínimos cuadrados de la pendiente β_1 de la recta de regresión verdadera será entonces

$$\hat{\beta}_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2} = \frac{S_{xy}}{S_{xx}}$$

Otra forma de expresar a S_{xy} y S_{xx} es:

$$S_{xy} = \sum_{i=1}^n x_i y_i - \frac{\sum x_i \sum y_i}{n} \quad S_{xx} = \sum_{i=1}^n x_i^2 - \frac{(\sum x_i)^2}{n}$$

La estimación de mínimos cuadrados de la ordenada al origen β_0 es:

$$\hat{\beta}_0 = \frac{\sum y_i - \hat{\beta}_1 \sum x_i}{n} = \bar{y} - \hat{\beta}_1 \bar{x}$$

No olviden los sombreritos. ¡Estamos hablando de estimadores!

CONSIDERACIONES

Validez de la regresión

La recta de regresión es válida **únicamente** dentro del rango de valores de la variable x (interpolación). Por fuera de este rango, no se puede tomar como válido (Ej. 3).

Múltiples expresiones

Varias de las fórmulas tienen múltiples formas equivalentes de expresarse (Ej. 5). Tener en mente que cada una se puede requerir en distintos momentos según los datos dados (Ej. 7).

Fórmula de promedio

Uno de los elementos que suele aparecer en las fórmulas es la del promedio. El promedio puede aparecer como “(suma)/(cantidad)” o como “ $/x$ ”.


Calculadora Científica

Pueden ayudarse para realizar las cuentas en la práctica con la calculadora científica; la misma les permitirá ingresar los datos y calcular las sumatorias necesarias.

¿CÓMO SE SI UNA RECTA ES BUENA?

Todo conjunto de datos puede ser ajustado con un modelo de regresión lineal. Sin embargo, qué es lo que define que el ajuste de un modelo sea bueno o no?

Vamos a presentar entonces los conceptos de varianza, error explicado y no explicado, y la bondad del ajuste.



DEFINICIONES

Residuos

Los residuos, o errores, son la diferencia entre el valor estimado por la recta y los valores de la muestra

Variabilidad

Es la diferencia entre los valores de la muestra y el promedio entre ellos. Indica “qué tan variable” es el dato dependiente.

$$S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

SCE

La suma de cuadrados (SCE) es la suma de los cuadrados de los residuos. Indica la variabilidad no explicada por el modelo.

$$SCE = S_{yy} - \frac{(S_{xy})^2}{S_{xx}}$$

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n [y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_i)]^2$$

Varianza

Indica hasta qué tanto puede diferir el valor que estima la recta en relación a qué tan variable es la muestra.

$$\hat{\sigma}^2 = \frac{SCE}{n - 2}$$

COEFICIENTE DE DETERMINACIÓN

- Suma total de cuadrados

$$STC = S_{yy} = \sum_{i=1}^n (y_i - \bar{y})^2$$

- Suma de cuadrados de error

$$SCE = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Suma de cuadrados debido a la regresión

$$SCR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$$

Definición 1.6. *El coeficiente de determinación, denotado por R^2 , está dado por*

$$R^2 = 1 - \frac{SCE}{STC}$$

Se interpreta como la proporción de variación y observada que puede ser explicada por el modelo de regresión lineal simple (atribuida a una relación lineal aproximada entre y y x).

$$R^2 = 1 - \frac{SS_R}{S_{yy}}$$

Este coeficiente indica qué porcentaje de la variabilidad de y es explicado o representado por el modelo de regresión.

COEFICIENTE DE CORRELACIÓN

$$r = \frac{Cov(x, y)}{\sqrt{S_{xx}S_{yy}}} \quad r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} \quad r = \sqrt{R^2}$$

Este coeficiente indica qué tan lineal es la relación entre los datos que se obtuvieron.

- $r=1$: Relación lineal perfecta
- $r=-1$: Relación lineal negativa perfecta
- $r=0$: No hay relación




Figure 10: Interpretación gráfica de los distintos valores del coeficiente de correlación lineal



Universidad Nacional de La Plata

MUCHAS GRACIAS

¡A resolver la práctica!